



เอกสารโครงการ

การเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกเรย์ด้วยการลดสัญญาณรบกวน
และปัญญาประดิษฐ์ที่อธิบายได้

โดย

673380280-2 นายปิยะพล ตุ่นป่า

673380066-4 นายสัพพัญญู คำตุ้ม

เสนอ

อ. ดร.พบพร ด้านวิรุฑัย

ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์

วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

บทคัดย่อ

โครงการเรื่อง "การเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ด้วยการลดสัญญาณรบกวนและปัญญาประดิษฐ์ที่อธิบายได้" มีวัตถุประสงค์เพื่อทบทวนวรรณกรรมที่เกี่ยวข้องกับเทคนิคการลดสัญญาณรบกวน (Denoising) ในภาพเอกซเรย์ทรวงอก ร่วมกับเทคนิคปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI) สำหรับการจำแนกโรคทางการแพทย์ โดยมุ่งเน้นการนำไปประยุกต์ใช้ในการตรวจจับภาวะปอดอักเสบ (Infiltration) จากภาพถ่ายรังสีทรวงอกโดยเฉพาะ

คณะผู้จัดทำได้สังเคราะห์และเปรียบเทียบผลการศึกษางานวิจัยที่เกี่ยวข้องจำนวน 10 ฉบับครอบคลุมช่วงปี ค.ศ. 2021–2026 ผ่านตารางสังเคราะห์ (Synthesis Matrix) และการวิเคราะห์ความเกี่ยวข้องกับภาวะ Infiltration ผลการทบทวนพบว่าเทคนิคการลดสัญญาณรบกวนแบบผสมผสาน (Fusion/Ensemble) เช่น การรวม Denoising Autoencoder กับ CLAHE หรือ CLAHE กับ Discrete Wavelet Transform ให้ผลลัพธ์ดีกว่าการใช้เทคนิคเดี่ยวอย่างชัดเจน และ Explainable AI อย่าง Grad-CAM และ SHAP ได้รับการยอมรับว่าเป็นกุญแจสำคัญในการสร้างความน่าเชื่อถือทางคลินิก แต่ยังมีข้อจำกัดด้านความแม่นยำในการระบุตำแหน่งของรอยโรคที่มีลักษณะกระจายตัวไม่ชัดเจน (Diffuse Pattern) เช่นเดียวกับภาวะ Infiltration

จากการสังเคราะห์งานวิจัย พบว่ามีเพียงงานวิจัยของ Sheu และคณะ (2023) เท่านั้นที่ระบุเจาะจงถึงภาวะ Infiltration โดยตรง ในขณะที่งานวิจัยส่วนใหญ่มุ่งเน้นโรคที่มีขอบเขตชัดเจน เช่น Nodule หรือ Atelectasis คณะผู้จัดทำจึงระบุช่องว่างทางความรู้ (Research Gap) ที่สำคัญ 6 ประเด็น ได้แก่ การขาดเทคนิคลดสัญญาณรบกวนที่ออกแบบเฉพาะสำหรับลักษณะฝ้ากระจายของ Infiltration, การขาดการทดลอง Fusion Denoising กับภาวะนี้โดยตรง, ความเสี่ยงของ Over-smoothing ที่อาจทำให้รายละเอียดของรอยโรคหายไป, ความน่าเชื่อถือของ XAI ที่ยังไม่ชัดเจนกับรอยโรคแบบกระจายตัว, ปัญหา Label Noise ที่รุนแรงเป็นพิเศษเนื่องจากการประเมินแบบ Subjective และการขาดการเปรียบเทียบอย่างเป็นธรรม (Fair Comparison) ระหว่างตัวกรองแบบดั้งเดิมกับเทคนิคการเรียนรู้เชิงลึกบนชุดข้อมูลเดียวกัน

ผลการทบทวนงานวิจัยนี้นำไปสู่การกำหนดแนวทางการดำเนินโครงการต่อไป คือ การพัฒนาเทคนิคลดสัญญาณรบกวนแบบผสมผสานที่ควบคุมระดับการลด Noise เพื่อป้องกัน Over-smoothing การเปรียบเทียบประสิทธิภาพอย่างเป็นธรรมระหว่างตัวกรองแบบดั้งเดิมกับ Deep Learning และการประยุกต์ใช้ Grad-CAM และ SHAP เพื่อประเมินว่าการลดสัญญาณรบกวนช่วยเพิ่มความแม่นยำในการระบุตำแหน่งรอยโรคของ XAI สำหรับภาวะ Infiltration ได้จริงหรือไม่ อันจะเป็นประโยชน์ต่อการยกระดับความน่าเชื่อถือของระบบปัญญาประดิษฐ์ในการสนับสนุนการวินิจฉัยของบุคลากรทางการแพทย์ในอนาคต

คำสำคัญ: ภาวะปอดอักเสบ, การลดสัญญาณรบกวน, ปัญญาประดิษฐ์ที่อธิบายได้, ภาพเอกซเรย์ทรวงอก

คำนำ

รายงานฉบับนี้จัดทำขึ้นเพื่อนำเสนอโครงงานเรื่อง “การเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ด้วยการลดสัญญาณรบกวนและปัญญาประดิษฐ์ที่อธิบายได้” ซึ่งเป็นส่วนหนึ่งของรายวิชาในหลักสูตรสาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น ภาคการศึกษา ปีการศึกษา 2569

ภาวะปอดอักเสบ (Infiltration) เป็นภาวะที่ตรวจพบได้จากภาพถ่ายรังสีทรวงอก (Chest X-ray) และเป็นหนึ่งในสาเหตุสำคัญของการเจ็บป่วยและเสียชีวิตของประชากรทั่วโลก ปัจจุบันการวินิจฉัยด้วยภาพเอกซเรย์ยังคงต้องอาศัยความเชี่ยวชาญของรังสีแพทย์และมีข้อจำกัดด้านความแม่นยำ เนื่องจากภาพเอกซเรย์มักปรากฏสัญญาณรบกวน (Noise) ที่ส่งผลต่อคุณภาพของภาพและความถูกต้องในการวินิจฉัย คณะผู้จัดทำจึงมีความสนใจที่จะศึกษาและพัฒนาแนวทางการเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบ โดยอาศัยเทคนิคการลดสัญญาณรบกวนร่วมกับปัญญาประดิษฐ์ที่สามารถอธิบายผลการทำนายได้ (Explainable AI)

คณะผู้จัดทำหวังเป็นอย่างยิ่งว่ารายงานฉบับนี้จะเป็นประโยชน์ต่อผู้ที่สนใจศึกษาแนวทางการประยุกต์ใช้ปัญญาประดิษฐ์ในการวิเคราะห์ภาพทางการแพทย์

คณะผู้จัดทำ
นายสัพพัญญู คำตุ้ม
นายปิยะพล ตุ่นป่า

สารบัญ

บทคัดย่อ	ก
คำนำ	ข
สารบัญ	ค
สารบัญตาราง	จ
บทที่ 1 บทนำ	1
1.1 ที่มาและความสำคัญ	1
1.2 วัตถุประสงค์ของการศึกษา	1
1.3 ขอบเขตของการศึกษา	2
1.4 ประโยชน์ที่คาดว่าจะได้รับ	2
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	3
2.1 งานวิจัยที่เกี่ยวข้อง	3
2.1.1 A Study on Various Common Denoising Methods on Chest X-ray Images (Chattopadhyay, 2022)	3
2.1.2 Enhanced Ensemble Segmentation of Lung Chest X-Ray Images by Denoising Autoencoder and CLAHE (Thamilarasi, Asaithambi & Roselin, 2025)	3
2.1.3 Collapsed Lung Disease Classification by Coupling Denoising Algorithms and Deep Learning Techniques (Chutia, Tewari & Singh, 2023/2024)	3
2.1.4 Artificial Intelligence for Pulmonary Abnormality Detection in Chest X-Ray Imaging: A Detailed Review of Methods, Datasets and Future Directions (Parra-Cabrera, Jimenez- Delgado & Perez-Cano, 2026)	4
2.1.5 Explainable Artificial Intelligence for Deep Learning Methods in Chest X-Ray Classification (Chrysoula, 2023)	4
2.1.6 Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images (Rahman et al, 2021)	4
2.1.7 Artificial intelligence for chest X-ray image enhancement (Song et al 2025)	5
2.1.8 Privacy-preserving explainable AI enable federated learning-based denoising fingerprint recognition model (Byeon et al, 2025)	6
2.1.9 Interpretable Classification of Pneumonia Infection Using eXplainable AI (XAI-ICP) (Sheu et al, 2023)	6
2.1.10 Challenges of Deep Learning in Medical Image Analysis—Improving Explainability and Trust (Dhar et al, 2023)	7

2.2 ทฤษฎีที่เกี่ยวข้อง	7
2.2.1 เทคนิคการลดสัญญาณรบกวน (Denoising Techniques)	7
2.2.2 เทคนิคเพิ่มความคมชัดของภาพ (Contrast Enhancement)	8
2.2.3 การแปลงเวฟเลตแบบไม่ต่อเนื่อง (Discrete Wavelet Transform: DWT)	8
2.2.4 การแบ่งส่วนภาพแบบรวมหลายวิธี (Ensemble Segmentation)	8
2.2.5 Transfer Learning	8
2.2.6 Vision Transformer และ Vision-Language Model	8
2.2.7 ปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: Grad-CAM)	8
2.2.8 การเรียนรู้ด้วยตนเองแบบไม่มีผู้สอน (Self-Supervised Learning: SSL) และปัญหา Label Noise	9
2.3 เปรียบเทียบผลการศึกษา	9
2.3.1 การสังเคราะห์วิธีการลดสัญญาณรบกวนและโมเดลวิเคราะห์โรค	9
2.3.2 การวิเคราะห์ความเกี่ยวข้องกับภาวะ Infiltration เพื่อประเมินช่องว่างทางความรู้	10
2.3.3 การระบุช่องว่างทางความรู้ (Research Gap) เมื่อโฟกัสที่ภาวะ Infiltration	11
การทบทวนวรรณกรรมเชิงวิเคราะห์ (Literature Review)	12
บทที่ 3 สรุปผลการศึกษา	14
3.1 สรุปผล	14
3.2 แนวทางการนำไปใช้	15
เอกสารอ้างอิง	17

สารบัญตาราง

ตารางที่ 1 : ตารางสังเคราะห์งานวิจัยที่เกี่ยวข้อง (Synthesis Matrix)	10
ตารางที่ 2 : ความเกี่ยวข้องของโรค/ภาวะที่งานวิจัยแต่ละฉบับศึกษากับภาวะ Infiltration	11
ตารางที่ 3 : Research Gap เมื่อโฟกัสที่ภาวะ Infiltration	11

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญ

ภาวะปอดอักเสบ (Infiltration) เป็นความผิดปกติที่พบได้บ่อยในภาพถ่ายรังสีทรวงอก และมีความสัมพันธ์ใกล้ชิดกับโรคปอดบวม (Pneumonia) ซึ่งเป็นสาเหตุสำคัญของการเจ็บป่วยรุนแรงและการเสียชีวิตในหลายกลุ่มประชากร โดยเฉพาะเด็กเล็ก ผู้สูงอายุ และผู้ที่มีภูมิคุ้มกันบกพร่อง การวินิจฉัยที่รวดเร็วและแม่นยำจึงมีความสำคัญอย่างยิ่งต่อการรักษาและลดอัตราการเสียชีวิต

ในทางปฏิบัติการอ่านและแปลผลภาพเอกซเรย์ทรวงอกยังคงต้องอาศัยประสบการณ์และความเชี่ยวชาญของรังสีแพทย์ ซึ่งอาจเกิดความคลาดเคลื่อนได้จากหลายปัจจัย อาทิ ความเมื่อยล้าของผู้อ่านภาพ ปริมาณผู้ป่วยที่ต้องตรวจในแต่ละวัน รวมถึงคุณภาพของภาพเอกซเรย์เองที่มักปรากฏสัญญาณรบกวน (Noise) อันเกิดจากกระบวนการถ่ายภาพ อุปกรณ์ หรือสภาพแวดล้อม ซึ่งสัญญาณรบกวนเหล่านี้ส่งผลโดยตรงต่อความชัดเจนของรอยโรคในภาพ และอาจนำไปสู่การวินิจฉัยที่ผิดพลาดทั้งในรูปแบบผลบวกлож (False Positive) และผลลบлож (False Negative)

ในช่วงหลายปีที่ผ่านมา เทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence) และการเรียนรู้เชิงลึก (Deep Learning) ได้ถูกนำมาประยุกต์ใช้ในการจำแนกและตรวจจับความผิดปกติจากภาพทางการแพทย์อย่างแพร่หลาย และแสดงให้เห็นถึงศักยภาพในการช่วยสนับสนุนการวินิจฉัยของแพทย์ อย่างไรก็ตามแบบจำลองปัญญาประดิษฐ์ส่วนใหญ่ยังมีลักษณะเป็น “กล่องดำ” (Black Box) กล่าวคือให้ผลการทำนายโดยไม่สามารถอธิบายเหตุผลเบื้องหลังการตัดสินใจได้อย่างชัดเจน ซึ่งเป็นอุปสรรคสำคัญต่อการนำไปใช้งานจริงในบริบททางการแพทย์ที่ต้องอาศัยความน่าเชื่อถือและความโปร่งใสของผลการวินิจฉัยเป็นอย่างสูง

จากการทบทวนงานวิจัยที่เกี่ยวข้องกับการลดสัญญาณรบกวนในภาพเอกซเรย์และการจำแนกโรคด้วยปัญญาประดิษฐ์ พบว่ายังมีช่องว่างงานวิจัย ในประเด็นการศึกษาที่มุ่งเน้นการตรวจจับภาวะปอดอักเสบ (Infiltration) โดยตรงร่วมกับการอธิบายผลการทำนายของแบบจำลองอย่างเป็นระบบ คณะผู้จัดทำจึงเห็นความสำคัญในการพัฒนาแนวทางที่ผสมผสานการลดสัญญาณรบกวนในภาพเอกซเรย์เข้ากับเทคนิคปัญญาประดิษฐ์ที่สามารถอธิบายได้ (Explainable AI หรือ XAI) เพื่อเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบ ควบคู่ไปกับการสร้างความน่าเชื่อถือและความโปร่งใสให้แก่แบบจำลอง อันจะเป็นประโยชน์ต่อการนำไปประยุกต์ใช้สนับสนุนการวินิจฉัยของบุคลากรทางการแพทย์ในอนาคต

1.2 วัตถุประสงค์ของการศึกษา

1. เพื่อศึกษาและทบทวนวรรณกรรมที่เกี่ยวข้องกับเทคนิคการลดสัญญาณรบกวนในภาพเอกซเรย์ทรวงอก และเทคนิคปัญญาประดิษฐ์สำหรับการจำแนกโรคทางการแพทย์
2. เพื่อพัฒนาแบบจำลองปัญญาประดิษฐ์สำหรับตรวจจับภาวะปอดอักเสบ (Infiltration) จากภาพเอกซเรย์ทรวงอก โดยผ่านกระบวนการลดสัญญาณรบกวนก่อนการวิเคราะห์
3. เพื่อประยุกต์ใช้เทคนิคปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI) ในการอธิบายเหตุผลเบื้องหลังการทำนายของแบบจำลอง

4. เพื่อประเมินประสิทธิภาพของแบบจำลองที่พัฒนาขึ้น เปรียบเทียบกับแนวทางที่ไม่มีการลดสัญญาณรบกวน

1.3 ขอบเขตของการศึกษา

1. การศึกษาครั้งนี้ใช้ชุดข้อมูลภาพเอกซเรย์ทรวงอกที่เปิดเผยต่อสาธารณะโดยมุ่งเน้นเฉพาะการจำแนกความผิดปกติประเภทภาวะปอดอักเสบ (Infiltration)
2. ขอบเขตด้านเทคนิคครอบคลุมวิธีการลดสัญญาณรบกวนในภาพเอกซเรย์ (Image Denoising) และแบบจำลองการเรียนรู้เชิงลึก (Deep Learning) สำหรับการจำแนกภาพ ร่วมกับเทคนิคปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI) เพื่อแสดงพื้นที่ในภาพที่มีผลต่อการตัดสินใจของแบบจำลอง
3. การประเมินผลใช้ตัวชี้วัดมาตรฐานทางการจำแนกประเภท เช่น ความแม่นยำ (Accuracy) ความไว (Sensitivity) ความจำเพาะ (Specificity) และค่า F1-score เป็นหลัก
4. โครงการนี้จัดทำขึ้นเพื่อวัตถุประสงค์ทางการศึกษาและการวิจัยเบื้องต้นเท่านั้น มิได้มุ่งหมายให้นำไปใช้วินิจฉัยโรคทางคลินิกจริงโดยไม่ผ่านการตรวจสอบและรับรองจากผู้เชี่ยวชาญทางการแพทย์

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1. ได้แนวทางการเพิ่มประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ทรวงอกด้วยการลดสัญญาณรบกวนร่วมกับปัญญาประดิษฐ์
2. ได้แบบจำลองปัญญาประดิษฐ์ที่สามารถอธิบายเหตุผลของผลการทำนายได้ ซึ่งช่วยเพิ่มความน่าเชื่อถือและความโปร่งใสในการนำไปใช้สนับสนุนการวินิจฉัยของบุคลากรทางการแพทย์
3. เป็นแนวทางและองค์ความรู้พื้นฐานสำหรับการต่อยอดงานวิจัยด้านการประยุกต์ใช้ปัญญาประดิษฐ์ที่อธิบายได้ในภาพทางการแพทย์ประเภทอื่น ๆ ต่อไป
4. ผู้จัดทำได้ฝึกฝนทักษะการทบทวนวรรณกรรม การพัฒนาแบบจำลองปัญญาประดิษฐ์ และการวิเคราะห์ผลอย่างเป็นระบบ ซึ่งเป็นประโยชน์ต่อการศึกษาและการทำงานในอนาคต

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 งานวิจัยที่เกี่ยวข้อง

บทความวิจัยที่เกี่ยวข้องทั้ง 5 ฉบับ สามารถสรุปสาระสำคัญตามหลัก 5W1H (Who, What, When, Where, Why, How) ได้ดังนี้

2.1.1 A Study on Various Common Denoising Methods on Chest X-ray Images (Chattopadhyay, 2022)

งานวิจัยของ Chattopadhyay (2022) เปรียบเทียบตัวกรองลดสัญญาณรบกวน 4 ชนิดบนภาพเอกซเรย์ทรวงอกจำนวน 500 ภาพ พบว่า Median Filter ซึ่งเป็นตัวกรองแบบ Non-linear ให้ผลลัพธ์ที่ดีที่สุดในแง่คุณภาพภาพ (PSNR สูงสุด 34.52 dB) และความแม่นยำในการจำแนกวัณโรคด้วย k-means (92%) ผลการศึกษานี้ชี้ให้เห็นว่าการเลือกตัวกรองลดสัญญาณรบกวนที่เหมาะสมกับลักษณะสัญญาณรบกวนแบบ Poisson มีผลโดยตรงต่อประสิทธิภาพของขั้นตอนจำแนกโรคในลำดับถัดไป

2.1.2 Enhanced Ensemble Segmentation of Lung Chest X-Ray Images by Denoising Autoencoder and CLAHE (Thamilarasi, Asaithambi & Roselin, 2025)

งานวิจัยของ V. Thamilarasi และคณะ (2025) เสนอวิธี Ensemble Segmentation สำหรับภาพเอกซเรย์ปอด โดยใช้ Denoising Autoencoder และ CLAHE เพื่อปรับปรุงคุณภาพภาพก่อนรวมผลจากเทคนิค Segmentation 4 วิธี และใช้ Machine Learning จำแนกก้อนเนื้อ ผลการทดลองกับชุดข้อมูล JSRT พบว่าวิธีดังกล่าวสามารถแบ่งส่วนปอดได้แม่นยำ 97.67% และ SVM จำแนก Nodule/Non-nodule ได้แม่นยำ 98.93% และ Malignant/Benign ได้ 99.18%

จะเห็นได้ว่า การผสมผสานหลายเทคนิคช่วยเพิ่มความแม่นยำในการวิเคราะห์ภาพ X-ray และมีศักยภาพในการช่วยตรวจหาก้อนเนื้อและมะเร็งปอดได้อย่างมีประสิทธิภาพ

2.1.3 Collapsed Lung Disease Classification by Coupling Denoising Algorithms and Deep Learning Techniques (Chutia, Tewari & Singh, 2023/2024)

งานวิจัยของ Chutia และคณะ (2023/2024) เสนอวิธี Fusion ที่รวม CLAHE และ DWT เข้าด้วยกันก่อนนำเข้าโมเดล Modified DenseNet201 เพื่อจำแนกภาวะปอดยุบชนิด Atelectasis และ Pneumothorax ผลการทดลองแสดงให้เห็นว่าการผสมผสานสองเทคนิคเพิ่มคุณภาพภาพเข้าด้วยกันให้ความแม่นยำสูงถึง 97.77% ซึ่งดีกว่าการใช้เทคนิคใดเทคนิคหนึ่งเพียงอย่างเดียว (93-95%) สะท้อนให้เห็นว่าการเตรียมภาพที่ดีก่อนเข้าสู่โมเดล Deep Learning มีผลอย่างมากต่อประสิทธิภาพการจำแนกโรค

2.1.4 Artificial Intelligence for Pulmonary Abnormality Detection in Chest X-Ray Imaging: A Detailed Review of Methods, Datasets and Future Directions (Parra-Cabrera, Jimenez-Delgado & Perez-Cano, 2026)

บทความปริทัศน์ของ Parra-Cabrera และคณะ (2026) สัมเคราะห์แนวทาง AI ที่ใช้ตรวจจับความผิดปกติของปอดจากภาพเอกซเรย์ ตั้งแต่ CNN ตั้งเดิมไปจนถึง Vision Transformer และ Vision-Language Model ที่ทำงานแบบ Zero-shot ได้ พร้อมชี้ให้เห็นข้อจำกัดสำคัญของเทคนิคอธิบายผล (Explainability) อย่าง Grad-CAM ที่ยังไม่สามารถระบุตำแหน่งหรือพิสูจน์เหตุ-ผลได้แม่นยำพอ งานนี้จึงเสนอทิศทางการวิจัยในอนาคต เช่น การพัฒนา Foundation Model และการออกแบบประเมินผลที่เป็นมาตรฐานเดียวกัน เพื่อให้ระบบ AI วินิจฉัยโรคปอดมีความน่าเชื่อถือและนำไปใช้จริงได้มากขึ้น

2.1.5 Explainable Artificial Intelligence for Deep Learning Methods in Chest X-Ray Classification (Chrysoula, 2023)

วิทยานิพนธ์ของ Chrysoula (2023) ใช้ ResNet50 แบบ Transfer Learning จำแนกโรคทรวงอกหลายชนิดพร้อมกันบนชุดข้อมูล VinBigData และประเมินความน่าเชื่อถือของ Grad-CAM ในฐานะเทคนิค Explainable AI ผลการศึกษาชี้ว่าความแม่นยำของคำอธิบายจาก Grad-CAM แตกต่างกันไปตามชนิดโรค โดยระบุตำแหน่งโรคที่มีขนาดใหญ่ชัดเจนอย่าง Cardiomegaly ได้ดี แต่ยังไม่น่าเชื่อถือสำหรับโรคที่มีลักษณะกระจายไม่ชัดเจนอย่าง Pleural Thickening งานนี้จึงชี้ให้เห็นว่าความโปร่งใสของโมเดล AI ทางทางการแพทย์ยังมีข้อจำกัดที่แตกต่างกันในแต่ละประเภทโรค ซึ่งต้องพิจารณาอย่างระมัดระวังก่อนนำไปใช้ทางคลินิกจริง

2.1.6 Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images (Rahman et al, 2021)

งานวิจัยของ Rahman และคณะ (2021) ซึ่งตีพิมพ์ในวารสาร Computers in Biology and Medicine ได้นำเสนอการศึกษาผลกระทบของเทคนิคการปรับปรุงคุณภาพภาพ (image enhancement) ต่อประสิทธิภาพการตรวจจับโรค COVID-19 จากภาพเอกซเรย์ทรวงอก (CXR) โดยใช้ปัญญาประดิษฐ์ ผู้วิจัยชี้ให้เห็นว่างานวิจัยก่อนหน้านี้ส่วนใหญ่มักใช้ชุดข้อมูล COVID-19 ที่มีขนาดเล็กเกินไป ทำให้ยากต่อการนำผลลัพธ์ไปประยุกต์ใช้อย่างกว้างขวางในโลกจริง ด้วยเหตุนี้ ทีมวิจัยจึงได้รวบรวมชุดข้อมูลภาพเอกซเรย์ขนาดใหญ่ที่เรียกว่า COVQU dataset ซึ่งประกอบด้วยภาพทั้งหมด 18,479 ภาพ แบ่งเป็นภาพปกติ 8,851 ภาพ ภาพติดเชื้อปอดที่ไม่ใช่ COVID-19 จำนวน 6,012 ภาพ และภาพผู้ป่วย COVID-19 จำนวน 3,616 ภาพ พร้อมทั้งสร้าง ground truth lung mask ที่ผ่านการตรวจสอบโดยรังสีแพทย์ผู้เชี่ยวชาญ ซึ่งถือเป็นชุดข้อมูลสาธารณะที่มีภาพผู้ป่วย COVID-19 มากที่สุดในขณะนั้น การศึกษานี้ได้เปรียบเทียบเทคนิคการปรับปรุงภาพ 5 รูปแบบ ได้แก่ Histogram Equalization, CLAHE, Image Complement, Gamma Correction และ BCET ควบคู่กับการพัฒนาสถาปัตยกรรม Modified U-Net สำหรับการแบ่งส่วนปอด (lung segmentation) ซึ่งให้ผลลัพธ์ดีกว่า U-Net แบบมาตรฐาน โดยมีค่าความแม่นยำ Intersection-over-Union และ Dice coefficient สูงถึง 98.63%, 94.3% และ 96.94% ตามลำดับ จากนั้นนำภาพทั้งแบบดั้งเดิมและแบบ

ที่ผ่านการแบ่งส่วนปอดไปทดสอบกับโครงข่าย CNN ที่ผ่านการฝึกล่วงหน้า 7 แบบ ผลการทดลองพบว่าเทคนิค Gamma Correction ให้ประสิทธิภาพดีที่สุดในทุกกรณี โดยเมื่อใช้ภาพแบบไม่แบ่งส่วน โมเดล ChexNet ให้ความแม่นยำสูงถึง 96.29% ในขณะที่เมื่อใช้ภาพที่ผ่านการแบ่งส่วนปอดแล้ว โมเดล DenseNet201 ให้ความแม่นยำ 95.11% นอกจากนี้ ผู้วิจัยยังใช้เทคนิค Score-CAM ในการสร้างภาพ heat map เพื่อยืนยันว่าโมเดลตัดสินใจโดยอ้างอิงจากบริเวณปอดจริง ๆ ซึ่งช่วยเพิ่มความน่าเชื่อถือของระบบ AI ในการวินิจฉัยโรค ทั้งนี้ ผลการศึกษาชี้ให้เห็นว่าแม้ภาพที่ไม่ผ่านการแบ่งส่วนปอดอาจให้ความแม่นยำเชิงตัวเลขที่สูงกว่าเล็กน้อย แต่การแบ่งส่วนปอดกลับช่วยเพิ่มความน่าเชื่อถือของการตัดสินใจของโมเดลได้อย่างมีนัยสำคัญ ซึ่งมีความสำคัญอย่างยิ่งต่อการนำระบบไปประยุกต์ใช้จริงในทางการแพทย์

2.1.7 Artificial intelligence for chest X-ray image enhancement (Song et al 2025)

งานวิจัยของ Song และคณะ (2025) ซึ่งตีพิมพ์ในวารสาร Radiation Medicine and Protection ได้นำเสนอการทบทวนวรรณกรรมอย่างเป็นระบบเกี่ยวกับความก้าวหน้าของเทคนิคปัญญาประดิษฐ์ในการปรับปรุงคุณภาพภาพเอกซเรย์ทรวงอก (CXR) ในช่วงปี 2018–2023 โดยชี้ให้เห็นว่าภาพ CXR มีข้อจำกัดพื้นฐานจากหลักการถ่ายภาพที่โครงสร้างทางกายวิภาคถูกซ้อนทับกันในทิศทางเดียว ส่งผลให้โครงสร้างกระดูกสามารถบังรอยโรคในปอดได้มากถึงร้อยละ 35 ตามการศึกษาของ National Cancer Institute นอกจากนี้ noise และ artifact ในภาพยังก่อให้เกิดผลบวกเทียมที่เพิ่มภาระทางความคิดให้แพทย์รังสีและลดความสอดคล้องของผลการวินิจฉัยระหว่างผู้อ่านภาพ ด้วยเหตุนี้ ผู้วิจัยจึงจัดหมวดหมู่เทคนิคการปรับปรุงภาพออกเป็น 4 กลุ่มหลัก ได้แก่ การลบเงาโครงสร้างกระดูก (bone suppression) การลด noise ในภาพ (image denoising) การสร้างภาพความละเอียดสูงจากภาพต้นฉบับ (super-resolution reconstruction) และการเพิ่มความคมชัดของภาพ (contrast enhancement) ผ่านการสืบค้นวรรณกรรมจาก PubMed ร่วมกับการประชุมวิชาการชั้นนำด้าน computer vision และ medical imaging เช่น CVPR, ACCV และ MICCAI จนได้บทความที่เกี่ยวข้อง 51 ฉบับจาก 104 ฉบับที่พบในตอนแรก ผลการทบทวนพบว่าเทคนิคที่อาศัย Deep Learning (DL) โดยเฉพาะสถาปัตยกรรมแบบ Generative Adversarial Network (GAN) ให้ประสิทธิภาพเหนือกว่าวิธีดั้งเดิมที่ไม่ใช่ DL อย่างชัดเจนในแง่ความเร็วในการประมวลผลและคุณภาพของภาพที่ได้ โดยเฉพาะในงาน bone suppression และ image denoising ซึ่งพบว่าทุกบทความหรือส่วนใหญ่ใช้วิธี DL-based ในขณะที่งานด้าน contrast enhancement กลับยังพึ่งพาวิธีแบบดั้งเดิมเป็นหลัก ซึ่งบ่งชี้ถึงโอกาสในการพัฒนาต่อด้วยเทคนิค DL ในอนาคต อย่างไรก็ตาม ผู้วิจัยชี้ให้เห็นถึงความท้าทายร่วมที่ยังคงมีอยู่ ได้แก่ การขาดมาตรฐานในการประเมินผล ความยากในการรักษาความสมบูรณ์ของลักษณะทางพยาธิวิทยาที่ละเอียดอ่อนระหว่างกระบวนการปรับปรุงภาพ และช่องว่างระหว่างการวิจัยเชิงเทคนิคกับการนำไปใช้จริงทางคลินิก เนื่องจากงานวิจัยส่วนใหญ่ยังพึ่งพาข้อมูลสังเคราะห์มากกว่าข้อมูลจากผู้ป่วยจริง ทั้งนี้ ผู้วิจัยเสนอแนวทางในอนาคตว่าควรมีการพัฒนากรอบการทำงานแบบบูรณาการที่รวมหลายเทคนิคเข้าด้วยกัน เช่น การรวม denoising กับ super-resolution หรือ contrast enhancement พร้อมทั้งพัฒนาสถาปัตยกรรม DL ที่อาศัยหลักการทางฟิสิกส์ (physics-informed) เพื่อเพิ่มความสามารถในการอธิบายผลลัพธ์ควบคู่กับประสิทธิภาพที่สูง และผลักดันความร่วมมือระหว่างภาคอุตสาหกรรมในการ

สร้างชุดข้อมูลมาตรฐานแบบ DICOM เพื่อรองรับการตรวจสอบความถูกต้องทางคลินิกอย่างครอบคลุมต่อไป

2.1.8 Privacy-preserving explainable AI enable federated learning-based denoising fingerprint recognition model (Byeon et al, 2025)

งานวิจัยของ Byeon และคณะ (2025) ซึ่งตีพิมพ์ในวารสาร Image and Vision Computing ได้เสนอแนวทางแก้ไขข้อจำกัดสำคัญของระบบจดจำลายนิ้วมือแบบดั้งเดิมที่มักอาศัย Machine Learning แบบรวมศูนย์ (centralized) ซึ่งแม้จะให้ความแม่นยำสูง แต่กลับละเลยประเด็นความเป็นส่วนตัวของผู้ใช้และความแตกต่างของข้อมูลระหว่างผู้ใช้แต่ละราย (data heterogeneity) จนนำไปสู่ความเสี่ยงด้านการรั่วไหลของข้อมูลชีวมาตร (biometric data) และประสิทธิภาพการจดจำที่ลดลง ผู้วิจัยจึงพัฒนาอัลกอริทึมที่เรียกว่า AI-Fed-FR โดยผสานเทคนิคสามส่วนเข้าด้วยกัน ได้แก่ การใช้ Federated Learning เพื่อให้ผู้ใช้แต่ละคนฝึกโมเดลจากข้อมูลของตนเองในเครื่อง แล้วส่งเพียงพารามิเตอร์ของโมเดล (ไม่ใช่ข้อมูลดิบ) ไปรวมกันที่เซิร์ฟเวอร์กลางผ่านกระบวนการ FedAvg เพื่อสร้างโมเดลสากลที่มีประสิทธิภาพโดยไม่ละเมิดความเป็นส่วนตัว ประการที่สอง นำแนวคิด Explainable AI มาผสานกับทฤษฎี Sparse Representation ในการลด noise ของภาพลายนิ้วมือคุณภาพต่ำ โดยอาศัยเทคนิค K-SVD ในการฝึก dictionary และ Orthogonal Matching Pursuit (OMP) ในการสกัดค่าสัมประสิทธิ์แบบ sparse เพื่อคงโครงสร้างลายนิ้วมือไว้ให้สมบูรณ์ที่สุด และประการที่สาม เสนอกลยุทธ์การคัดเลือก client แบบ Reservoir Sampling เพื่อแก้ปัญหาความไม่เป็นธรรมที่เกิดจากลักษณะข้อมูลที่ไม่เหมือนกันในแต่ละ client ทำให้ทุก client มีโอกาสเท่าเทียมกันในการเข้าร่วมกระบวนการฝึกโมเดล ผลการทดลองบนชุดข้อมูลจริงสามชุด ได้แก่ SOCOFing, SFinGe และ FVC2004 แสดงให้เห็นว่า AI-Fed-FR มีความแม่นยำสูงกว่าวิธี Local Learning ถึง 5.32% และสูงกว่าอัลกอริทึม FedAvg ถึง 8.56% โดยมีความแม่นยำใกล้เคียงกับวิธี Centralized Learning ทั้งนี้ งานวิจัยนี้ถือเป็นการศึกษาแรกที่พิสูจน์ความเป็นไปได้ในการผสาน Federated Learning เข้ากับงานจดจำลายนิ้วมือ ซึ่งช่วยเสริมสร้างทั้งความปลอดภัยและความสามารถในการขยายขนาด (scalability) ของระบบ อันเป็นประโยชน์ต่อการประยุกต์ใช้ Federated Learning ในเทคโนโลยีชีวมาตรอื่น ๆ ต่อไปในอนาคต

2.1.9 Interpretable Classification of Pneumonia Infection Using eXplainable AI (XAI-ICP) (Sheu et al, 2023)

งานวิจัยของ Sheu และคณะ (2023) ซึ่งตีพิมพ์ใน IEEE Access ได้นำเสนอระบบที่เรียกว่า XAI-ICP (Explainable AI for Interpretable Classification of Pneumonia) ซึ่งถูกออกแบบมาเพื่อแก้ไขข้อจำกัดสำคัญของโมเดล CNN แบบดั้งเดิมในการวินิจฉัยโรคปอดบวมจากภาพเอกซเรย์ทรวงอก กล่าวคือ แม้โมเดลเหล่านี้จะให้ความแม่นยำสูง แต่กระบวนการตัดสินใจภายในยังคงเป็นความลับ (black box) ทำให้แพทย์ผู้ตรวจยังไม่มั่นใจในผลลัพธ์อย่างเต็มที่ ด้วยเหตุนี้ ทีมผู้วิจัยจึงพัฒนาสถาปัตยกรรมโดยอาศัย DenseNet-121 ร่วมกับชั้นที่สามารถตีความได้ (interpretable layers) โดยเริ่มจากการ pre-train โมเดลด้วยชุดข้อมูลเปิดขนาดใหญ่จาก NIH จากนั้นจึงนำมาฝึกและปรับแต่งต่อด้วยข้อมูลจากโรงพยาบาล Taichung Veterans General Hospital (TCVGH)

ผสมผสานกับชุดข้อมูลเปิด VinDr จากเวียดนามผ่านเทคนิค Transfer Learning เพื่อให้ระบบสามารถปรับใช้ข้ามพรมแดนได้ นอกจากนี้ ยังมีการนำแนวทาง Human-in-the-loop มาใช้ โดยให้แพทย์ผู้เชี่ยวชาญมีส่วนร่วมในการติดป้ายกำกับข้อมูลลักษณะสำคัญ 3 ประการ ได้แก่ infiltrate, cardiomegaly และ effusion เพื่อเพิ่มความแม่นยำของโมเดล ควบคู่กับการใช้เครื่องมือ XAI อย่าง SHAP และ GRAD-CAM ในการแสดงให้เห็นตำแหน่งและระดับความรุนแรงของการติดเชื้อบนภาพเอกซเรย์อย่างชัดเจน ผลการทดลองพบว่าระบบสามารถให้ความแม่นยำถึง 92.14% เมื่อฝึกแบบอิสระ (independent learning) และเพิ่มขึ้นเป็น 93.29% เมื่อใช้ร่วมกับ Transfer Learning ซึ่งแสดงให้เห็นว่าการผสมผสานความโปร่งใสของโมเดลเข้ากับกระบวนการเรียนรู้แบบถ่ายโอนสามารถเพิ่มความน่าเชื่อถือและประสิทธิภาพของระบบวินิจฉัยโรคปอดบวมได้อย่างมีนัยสำคัญ

2.1.10 Challenges of Deep Learning in Medical Image Analysis—Improving Explainability and Trust (Dhar et al, 2023)

บทความของ Dhar และคณะ (2023) ซึ่งตีพิมพ์ใน IEEE Transactions on Technology and Society ได้นำเสนอปัญหาสำคัญที่ขัดขวางการนำเทคโนโลยี deep learning มาประยุกต์ใช้ในการวิเคราะห์ภาพทางการแพทย์อย่างเต็มรูปแบบ โดยผู้วิจัยชี้ให้เห็นว่าความท้าทายหลักมีสี่ประการ ได้แก่ ความเสี่ยงจากการถูกโจมตีของโมเดลเนื่องจาก noise และ artefact ในภาพทางการแพทย์ การขาดแคลนข้อมูลภาพที่มีคุณภาพและมีความสมดุลเพียงพอสำหรับการฝึกโมเดล ปัญหาด้านความไว้วางใจของผู้ใช้งานอันเนื่องมาจากลักษณะการทำงานแบบ "กล่องดำ" ของโมเดลที่ยากต่อการอธิบาย และประเด็นด้านความเป็นส่วนตัวและกฎหมายที่เกี่ยวข้องกับข้อมูลผู้ป่วย ทั้งนี้ ผู้วิจัยเสนอว่าการแก้ไขปัญหาดังกล่าวสามารถทำได้ผ่านเทคนิคต่าง ๆ เช่น การเสริมข้อมูลด้วย generative adversarial networks (GANs) การฝึกโมเดลให้ทนทานต่อการโจมตี (adversarial training) และการนำเครื่องมือปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI) มาใช้ร่วมด้วย เพื่อเสริมสร้างความน่าเชื่อถือระหว่างสังคมและระบบสนับสนุนการวินิจฉัยด้วยคอมพิวเตอร์ (CAD) ในระยะยาว

2.2 ทฤษฎีที่เกี่ยวข้อง

จากการทบทวนบทความวิจัยทั้ง 10 ฉบับ สามารถสรุปทฤษฎีและเทคนิคหลักที่เกี่ยวข้องได้ดังนี้

2.2.1 เทคนิคการลดสัญญาณรบกวน (Denoising Techniques)

แบ่งเป็น 2 กลุ่มหลัก คือ

1. Spatial Filtering แบบดั้งเดิม ได้แก่ Median Filter, Gaussian Filter, Bilateral Filter และ Moving Average Filter ซึ่งเป็น Deterministic Algorithm ที่คำนวณจากค่าพิกเซลรอบข้างโดยตรง ไม่ต้องเรียนรู้จากข้อมูล
2. เทคนิคที่อาศัยการเรียนรู้ ได้แก่ Denoising Autoencoder (DAE) ซึ่งเป็นโครงข่ายประสาทเทียมแบบ Encoder-Decoder ที่เรียนรู้บีบอัดและสร้างภาพกลับคืนโดยตัดสัญญาณรบกวนออก

2.2.2 เทคนิคเพิ่มความคมชัดของภาพ (Contrast Enhancement)

CLAHE (Contrast Limited Adaptive Histogram Equalization) เป็นเทคนิคที่แบ่งภาพเป็นบล็อกย่อยและปรับ Histogram ของแต่ละบล็อกแยกกัน พร้อมจำกัดค่า Clip Limit เพื่อป้องกันการขยายสัญญาณรบกวนใหม่ ทำให้ภาพมีความคมชัดมากขึ้นโดยไม่สูญเสียรายละเอียดสำคัญ

2.2.3 การแปลงเวฟเลตแบบไม่ต่อเนื่อง (Discrete Wavelet Transform: DWT)

เป็นเทคนิคแยกภาพออกเป็นส่วนความถี่ต่ำ (แสดงโครงสร้างหลักของภาพ) และความถี่สูง (มักมีสัญญาณรบกวนปน อยู่) ทำให้สามารถตัดส่วนความถี่สูงที่ไม่ต้องการออกเพื่อลดสัญญาณรบกวนได้

2.2.4 การแบ่งส่วนภาพแบบรวมหลายวิธี (Ensemble Segmentation)

เป็นการรวมผลจากเทคนิค Segmentation หลายแบบ เช่น Canny Edge Detection ร่วมกับ Morphology, Otsu Thresholding, Automatic Thresholding และ Granule Segmentation โดยใช้กติกาเสียงข้างมาก (Majority Voting) เพื่อเพิ่มความแม่นยำและความเสถียรของการแบ่งส่วนภาพ

2.2.5 Transfer Learning

การนำโมเดล Convolutional Neural Network ที่ผ่านการเทรนมาแล้วบนชุดข้อมูลขนาดใหญ่ เช่น ImageNet (ตัวอย่างเช่น ResNet50, DenseNet201) มาปรับจูนต่อ (Fine-tuning) สำหรับงานจำแนกภาพทางการแพทย์ ช่วยลด ความต้องการข้อมูลและเวลาในการเทรนโมเดลใหม่

2.2.6 Vision Transformer และ Vision-Language Model

Vision Transformer (ViT) แบ่งภาพออกเป็น Patch ย่อยแล้วใช้กลไก Self-Attention มองความสัมพันธ์ระหว่าง ทุกส่วนของภาพ เหมาะกับโรคที่มีลักษณะกระจายในหลายตำแหน่ง ส่วน Vision-Language Model (VLM) เช่น BioViL และ CheXzero เรียนรู้ความสัมพันธ์ระหว่างภาพ และรายงานทางการแพทย์ ทำให้สามารถจำแนกโรคแบบ Zero-shot (ไม่ต้องเทรนเฉพาะโรคนั้นมาก่อน) ได้

2.2.7 ปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: Grad-CAM)

Grad-CAM (Gradient-weighted Class Activation Mapping) เป็นเทคนิคสร้าง Heatmap เพื่ออธิบายว่าโมเดล ให้ความสำคัญกับบริเวณใดของภาพในการตัดสินใจ ช่วยเพิ่มความโปร่งใสของโมเดล Deep Learning แต่มีข้อจำกัด คือ Heatmap มีความละเอียดต่ำ อาจชี้ตำแหน่งผิด (เช่น ไปที่อุปกรณ์การแพทย์) และไม่สามารถพิสูจน์ความเป็นเหตุ เป็นผล (Causality) ได้อย่างสมบูรณ์

2.2.8 การเรียนรู้ด้วยตนเองแบบไม่มีผู้สอน (Self-Supervised Learning: SSL) และปัญหา Label Noise

Label Noise คือความผิดพลาดของป้ายกำกับข้อมูล ซึ่งพบมากในชุดข้อมูลขนาดใหญ่ที่ใช้ AI/NLP อ่านรายงาน แพทย์แล้วติดป้ายอัตโนมัติ เช่น ChestX-ray14 การใช้ Self-Supervised Learning ให้โมเดลเรียนรู้ลักษณะสำคัญ ของภาพจากข้อมูลที่ไม่ติดป้ายจำนวนมากก่อน แล้วจึงนำไป จำแนกโรคต่อ เป็นแนวทางหนึ่งที่จะช่วยลดผลกระทบจาก ปัญหา Label Noise ได้

2.3 เปรียบเทียบผลการศึกษา

จากการทบทวนวรรณกรรมที่เกี่ยวข้องกับการลดสัญญาณรบกวนและการตรวจจับความผิดปกติใน ภาพเอกซเรย์ทรวงอก ผู้วิจัยได้ทำการสังเคราะห์และเปรียบเทียบผลการศึกษาจากงานวิจัยที่เกี่ยวข้องจำนวน 10 ฉบับ โดยแบ่งการนำเสนอออกเป็น 3 ส่วนหลัก ได้แก่ การสังเคราะห์เทคนิคและผลลัพธ์ (Synthesis Matrix), การวิเคราะห์ความเกี่ยวข้องกับความ Infiltration และการระบุช่องว่างทางความรู้ (Research Gap)

2.3.1 การสังเคราะห์วิธีการลดสัญญาณรบกวนและโมเดลวิเคราะห์โรค

สรุปการเปรียบเทียบเทคนิคการลดสัญญาณรบกวน โมเดลที่ใช้ในการวิเคราะห์โรค และ ผลลัพธ์ประสิทธิภาพของแต่ละงานวิจัย ดังนี้

ผู้แต่งและปี	เทคนิคการลด Noise / Preprocessing	โมเดล AI ที่ใช้	เทคนิค Explainable AI (XAI)	ผลลัพธ์ประสิทธิภาพ	ข้อจำกัด / Research Gap
Rahman et al. (2021)	Gamma Correction, CLAHE, U-Net Segmentation	ChexNet, DenseNet201, ResNet	Score-CAM	Accuracy 95.11%, F1-score 94.53%	เน้นภาพรวมปอดอักเสบ ยังไม่เจาะจง Infiltration แบบฝ้ายกระจาย
Song et al. (2025)	Deep Learning-based Denoising, Bone Suppression	รวบรวมหลายสถาปัตยกรรม DL (Review)	ไม่มี	ลด False Positive/Negative ได้มีนัยสำคัญ	เป็นบทความ Review ยังไม่ได้ทดสอบผลกระทบต่อ XAI โดยตรง
Byeon et al. (2025)	Contourlet Transform, OMP, K-SVD	ResNet18 + Federated Learning	XAI-based Feature Enhancement	แม่นยำขึ้น 5.32% เมื่อเทียบกับ Local Learning	ทดสอบกับข้อมูลหลายนิ้วมือ ไม่ใช่ภาพ CXR
Sheu et al. (2023)	Image Quality Filtering (ตัดภาพ Noise ออก)	Re-configurable DCNN + Transfer Learning	SHAP (เทียบกับ Grad-CAM)	Accuracy 92.14% – 93.29% (เน้น Infiltrate)	ใช้วิธีตัดภาพทั้งแทนการกู้คืนภาพ (Restoration)

Dhar et al. (2023)	Preprocessing & Data Augmentation	Deep Neural Networks (CNNs)	XAI for Clinical Trust	สรุปปัญหา Adversarial Attacks จาก Noise	เป็นบทความเชิงแนวคิด ไม่มีกรอบการทดลองเปรียบเทียบ
Chattopadhyay (2022)	Spatial Filtering (Median, Gaussian, Bilateral)	k-means Clustering	ไม่มี	PSNR 34.52 dB, Accuracy 92% (วัณโรค)	ไม่ใช่ Deep Learning และไม่มี XAI
Thamilarasi et al. (2025)	Denoising Autoencoder (DAE) + CLAHE	Ensemble Segmentation + SVM/KNN/RF	ไม่มี	Segmentation 97.67%, Classification 99.18%	เน้น Nodule/Malignancy ไม่มี XAI
Chutia et al. (2023)	CLAHE + DWT (Fusion Approach)	Modified DenseNet201	ไม่มี	Accuracy 97.77% (Atelectasis/Pneumothorax)	ไม่มี XAI และไม่ได้เจาะจงภาวะ Infiltration
Chrysoula (2023)	ไม่มีขั้นตอนลด Noise	ResNet50 (Multilabel Classification)	Grad-CAM	F1 Score เฉลี่ย 0.81 (Lung Opacity 0.55)	ไม่มี Noise Reduction, Grad-CAM สัมพันธ์กับรอยโรคขอบเขตไม่ชัด
Parra-Cabrera et al. (2026)	Label Noise, Self-Supervised Learning (SSL)	CNN, ViT, Vision-Language Models	Grad-CAM, Causality	Zero-shot Classification	เป็นบทความ Review, ปัญหา Label Noise ใน Infiltration ยังไม่ถูกแก้

ตารางที่ 1 : ตารางสังเคราะห์งานวิจัยที่เกี่ยวข้อง (Synthesis Matrix)

2.3.2 การวิเคราะห์ความเกี่ยวข้องกับภาวะ Infiltration เพื่อประเมินช่องว่างทางความรู้

ผู้วิจัยได้ทำการวิเคราะห์ว่าโรคหรือภาวะที่งานวิจัยทั้ง 10 ฉบับศึกษานั้น มีความใกล้เคียงหรือเกี่ยวข้องกับ "ภาวะปอดอักเสบ (Infiltration)" มากน้อยเพียงใด

ผู้แต่งและปี	โรค/ภาวะที่จำแนกจริง	ความเกี่ยวข้องกับ Infiltration
Rahman et al. (2021)	COVID-19 / General Pneumonia	ทางอ้อม : มักแสดงลักษณะ Infiltration แต่ไม่ได้ระบุแยกเป็นคลาสเฉพาะเจาะจง
Song et al. (2025)	ภาพรวมความผิดปกติของปอด	กล่าวถึงในภาพรวม : ครอบคลุมหลายโรค แต่ไม่มีรายละเอียดเชิงลึกเฉพาะ Infiltration
Byeon et al. (2025)	ลายนิ้วมือ (Fingerprint)	ไม่เกี่ยวข้อง : เป็นโดเมนข้อมูลคนละประเภทกับภาพทางการแพทย์ (CXR)
Sheu et al. (2023)	Pneumonia Infection (Infiltrate)	เกี่ยวข้องโดยตรง : เน้นที่ Infiltrate เป็นหลัก แต่ใช้วิธีคัดภาพทั้งแทนการกู้คืน
Dhar et al. (2023)	ภาพรวม Medical Image Analysis	กล่าวถึงในภาพรวม : เน้นแนวคิด Trust และ Explainability แต่ยังไม่มีการทดลอง
Chattopadhyay (2022)	วัณโรค (Tuberculosis)	ทางอ้อม : มักแสดงลักษณะ Infiltration แต่ไม่ได้ระบุแยกเป็นคลาสเฉพาะ
Thamilarasi et al. (2025)	Nodule/Non-nodule, Malignant/Benign	ไม่เกี่ยวข้องโดยตรง : เน้นก้อนเนื้อที่มีขอบเขตชัดเจน ต่างจาก Infiltration ที่เป็นฝ้ากระจาย

Chutia et al. (2023)	Atelectasis, Pneumothorax, Normal	ไม่เกี่ยวข้องโดยตรง : เป็นภาวะปอดยุบ/ลมรั่ว ไม่ใช้การแทรกซึมของของเหลว
Chrysoula (2023)	Lung Opacity, Pleural Effusion, etc.	ใกล้เคียงที่สุด : Lung Opacity มีลักษณะทับซ้อนกับ Infiltration แต่ให้ผลลัพธ์แย่ที่สุด (F1 = 0.55)
Parra-Cabrera et al. (2026)	ภาพรวม Pulmonary Abnormality	กล่าวถึงในภาพรวม : ขี้ปัญหา Label Noise ใน ChestX-ray14 แต่ยังไม่แก้เฉพาะเจาะจง

ตารางที่ 2 : ความเกี่ยวข้องของโรค/ภาวะที่งานวิจัยแต่ละฉบับศึกษากับภาวะ Infiltration

บทวิเคราะห์จากตารางที่ 2 ข้อสังเกตที่สำคัญที่สุดจากการวิเคราะห์เปรียบเทียบคือ มีเพียงงานวิจัยของ Sheu et al. (2023) เท่านั้นที่ระบุเจาะจงถึงภาวะ Infiltrate โดยตรง ในขณะที่งานวิจัยส่วนใหญ่เน้นไปที่โรคที่มีขอบเขตชัดเจน (เช่น Nodule, Atelectasis) หรือโรคติดเชื้อเฉพาะ (เช่น TB) ภาวะ Lung Opacity ในงานของ Chrysoula (2023) แม้จะมีลักษณะทางภาพทับซ้อนกับ Infiltration มากที่สุด แต่กลับให้ค่า F1-Score ต่ำที่สุดเพียง 0.55 ซึ่งสะท้อนให้เห็นว่าโมเดลและเทคนิคปัจจุบันยังล้มเหลวในการตรวจจบบรรยากาศที่มีลักษณะเป็นฝ้ากระจาย (Diffuse Opacity) นี่คือช่องว่างงานวิจัย (Research Gap) หลักที่งานวิจัยนี้จะเข้าไปเติมเต็ม (Fill the gap)

2.3.3 การระบุช่องว่างทางความรู้ (Research Gap) เมื่อโฟกัสที่ภาวะ Infiltration

จากข้อค้นพบข้างต้น ผู้วิจัยได้สังเคราะห์และแจกแจงช่องว่างทางความรู้ (Research Gap) ออกเป็น 6 ประเด็นย่อย ที่งานวิจัยนี้จะเข้าไปดำเนินการแก้ไขและศึกษาเพิ่มเติม

ช่องว่างทางความรู้ (Research Gap)	สิ่งที่งานวิจัยเดิมทำได้ / ข้อจำกัด	อ้างอิง
ลักษณะขอบเขตไม่ชัดเจน (Diffuse Pattern)	Lung Opacity/Pleural Thickening ให้ F1 ต่ำสุด (0.55) และ Grad-CAM ระบุตำแหน่งไม่ได้	ยังไม่มีการศึกษาว่าเทคนิคลดสัญญาณรบกวนแบบใดช่วยเพิ่มความแม่นยำของภาวะฝ้ากระจายไม่มีขอบชัดโดยเฉพาะ
Fusion Denoising Approach สำหรับ Infiltration	CLAHE+DWT หรือ DAE+CLAHE ปรับปรุงผลลัพธ์ได้สูง (97-99%) แต่ทดสอบเฉพาะ Nodule หรือ Atelectasis	ยังไม่มีการทดลอง Fusion Approach กับภาวะ Infiltration โดยเฉพาะ
การกู้คืนภาพ (Restoration) แทนการคัดทิ้ง (Filtering)	งานส่วนใหญ่เลือกคัดภาพคุณภาพต่ำทิ้ง (Quality Filtering) ซึ่งทำให้สูญเสียข้อมูลทางการแพทย์	ยังขาดอัลกอริทึมที่พยายาม "กู้คืนภาพ" ที่มี Noise สูงให้กลับมาวิเคราะห์หรือโรค Infiltration ได้
ความน่าเชื่อถือของ XAI กับภาวะกระจายตัว	Grad-CAM ระบุตำแหน่ง Cardiomegaly ได้ดี แต่ล้มเหลวกับรอยโรคแบบ Diffuse; Heatmap ความละเอียดต่ำ	ยังไม่มีการประเมินว่า Noise Reduction จะช่วยให้ XAI Heatmap (เช่น SHAP, Score-CAM) ชี้ตำแหน่ง Infiltration ได้ชัดเจนขึ้นหรือไม่
ปัญหา Label Noise เฉพาะภาวะ Infiltration	ชุดข้อมูลขนาดใหญ่ (เช่น ChestX-ray14) มี Label Noise สูงจากการติดป้ายอัตโนมัติด้วย NLP	Infiltration มีการประเมินแบบ Subjective สูง ทำให้ Label Noise รุนแรงกว่าภาวะอื่น แต่ยังไม่ม้งานวิจัยที่แก้ปัญหานี้เฉพาะเจาะจง
Fair Comparison: Traditional vs. DL Denoising	งานวิจัยทดสอบ Traditional Filter (เช่น Median) กับ k-means หรือทดสอบ DL Denoising แยกกัน	ยังไม่มีกรทดลองเปรียบเทียบทั้งสองแนวทางบนงานเดียวกันอย่างยุติธรรม (Fair Comparison) สำหรับ Infiltration โดยเฉพาะ

ตารางที่ 3 : Research Gap เมื่อโฟกัสที่ภาวะ Infiltration

การทบทวนวรรณกรรมเชิงวิเคราะห์ (Literature Review)

จากการสังเคราะห์งานวิจัยทั้ง 10 ฉบับ พบว่าประเด็นที่งานวิจัยส่วนใหญ่เห็นตรงกัน (Consensus) คือ สัญญาณรบกวน (Noise) และสิ่งแปลกปลอมในภาพเอกซเรย์ทรวงอกส่งผลกระทบต่อความแม่นยำของโมเดลปัญญาประดิษฐ์ ทำให้เกิดผลลบปลอม (False Negative) และผลบวกปลอม (False Positive) การประมวลผลภาพขั้นต้น (Preprocessing) และการลดสัญญาณรบกวน (Noise Reduction) จึงเป็นขั้นตอนที่ขาดไม่ได้ งานวิจัยของ Rahman et al. (2021) พบว่าการใช้ Gamma Correction ร่วมกับ CLAHE และ U-Net Segmentation ช่วยเพิ่มความแม่นยำได้ถึง 95.11% ขณะที่ Thamilarasi et al. (2025) และ Chutia et al. (2023) พิสูจน์ให้เห็นว่าการใช้เทคนิคแบบผสมผสาน (Fusion/Ensemble Approach) เช่น การรวม DAE กับ CLAHE หรือการรวม CLAHE กับ DWT สามารถลดค่า Loss ลงได้ถึง 58% และเพิ่ม Accuracy สูงสุดถึง 97.77% ซึ่งดีกว่าการใช้เทคนิคเดียวอย่างชัดเจน นอกจากนี้ งานวิจัยยังเห็นตรงกันว่า Explainable AI (XAI) เป็นกุญแจสำคัญในการสร้างความเชื่อมั่นทางคลินิก (Clinical Trust) โดย Sheu et al. (2023) และ Rahman et al. (2021) ได้นำ SHAP และ Score-CAM มาใช้ชี้ตำแหน่งรอยโรค ซึ่งช่วยให้รังสีแพทย์เข้าใจเหตุผลในการตัดสินใจของโมเดล

อย่างไรก็ตาม งานวิจัยแต่ละฉบับมีแนวทางและข้อจำกัดที่แตกต่างกันอย่างชัดเจน (Disagreements & Differences) โดยเฉพาะด้านเทคนิคการลดสัญญาณรบกวนและโรคเป้าหมาย งานวิจัยของ Chattopadhyay (2022) ยังคงยืนยันประสิทธิภาพของตัวกรองแบบดั้งเดิม (Traditional Filter) อย่าง Median Filter สำหรับสัญญาณรบกวนแบบ Poisson ในขณะที่ Song et al. (2025) และ Thamilarasi et al. (2025) สนับสนุนการใช้ Deep Learning-based Denoising (เช่น DAE) ที่สามารถเรียนรู้และกู้คืนรายละเอียดของภาพได้ดีกว่า ในด้านการจัดการภาพที่มีสัญญาณรบกวนสูง Sheu et al. (2023) เลือกใช้วิธีคัดกรองและตัดภาพทิ้ง (Quality Filtering) ซึ่งต่างจากงานวิจัยอื่นๆ ที่พยายามกู้คืนภาพ (Image Restoration) ด้านโรคเป้าหมาย งานวิจัยส่วนใหญ่เน้นตรวจจ็บบรอยโรคที่มีขอบเขตชัดเจน เช่น วัณโรค (Chattopadhyay, 2022), ก้อนเนื้อ Nodule (Thamilarasi et al., 2025) หรือภาวะปอดยุบตัว (Chutia et al., 2023) ซึ่งมีลักษณะทางภาพที่แตกต่างจากภาวะปอดอักเสบ (Infiltration) อย่างสิ้นเชิง ภาวะ Infiltration มีลักษณะเป็นฝ้ากระจายขอบเขตไม่ชัดเจน (Diffuse/Hazy Opacity) ซึ่งงานวิจัยของ Chrysoula (2023) พบว่าแม้จะใช้ Grad-CAM กับภาวะ Lung Opacity ที่ใกล้เคียงกันที่สุด แต่กลับให้ค่า F1-Score ต่ำที่สุดเพียง 0.55 และ Grad-CAM ยังไม่สามารถระบุตำแหน่งของรอยโรคแบบกระจายตัวได้อย่างน่าเชื่อถือ

จากข้อค้นพบดังกล่าว สามารถสรุปช่องว่างทางความรู้ (Research Gap) ที่สำคัญ ซึ่งงานวิจัยนี้จะเข้าไปเติมเต็ม (Fill the gap) ประการแรก คือ การขาดการเชื่อมโยงระหว่าง Noise Reduction และ XAI งานวิจัยส่วนใหญ่ทำเพียงอย่างใดอย่างหนึ่ง ยังขาดการศึกษาอย่างเป็นระบบว่าการลดสัญญาณรบกวนส่งผลต่อความชัดเจนและความน่าเชื่อถือของ XAI Heatmap ในการตรวจจ็บบภาวะ Infiltration อย่างไร ประการที่สอง คือ การขาดการเจาะจงภาวะ Infiltration โดยตรง งานวิจัยเดิมส่วนใหญ่ล้มเหลวในการตรวจจ็บบรอยโรคแบบ Diffuse Pattern และยังไม่มีการศึกษาว่าการลดสัญญาณรบกวนที่รุนแรงเกินไป (Over-smoothing) จะไปกลบรายละเอียดของฝ้าบางจางของ Infiltration จนหายไปหรือไม่ ประการที่สาม คือ ปัญหาคุณภาพข้อมูล (Label Noise) ซึ่ง Parra-Cabrera et al. (2026) ชี้ให้เห็นว่าชุดข้อมูลขนาดใหญ่มี Label Noise สูง และภาวะ Infiltration มีการประเมินแบบ Subjective สูง ทำให้ยังไม่มีงานวิจัยใดที่วัดหรือแก้ปัญหานี้

เฉพาะเจาะจง และประการที่สี่ คือ การขาดการเปรียบเทียบอย่างเป็นธรรม (Fair Comparison) ระหว่าง Traditional Filter และ Deep Learning Denoising บนชุดข้อมูลและงานเฉพาะทางเดียวกัน

ดังนั้น งานวิจัยนี้จึงมีวัตถุประสงค์เพื่อเติมเต็มช่องว่างดังกล่าว โดยการพัฒนา Fusion Denoising Technique ที่ออกแบบมาเพื่อรักษารายละเอียดของผ้าบางจาง (Prevent Over-smoothing) ควบคู่ไปกับการเปรียบเทียบประสิทธิภาพอย่างเป็นธรรมระหว่างตัวกรองแบบดั้งเดิมและ Deep Learning Denoising พร้อมทั้งประเมินและปรับปรุงความน่าเชื่อถือของ XAI เพื่อพิสูจน์ว่าเทคนิคลดสัญญาณรบกวนที่เลือกใช้สามารถช่วยให้ Heatmap ชี้ตำแหน่งรอยโรค Infiltration ได้แม่นยำและน่าเชื่อถือมากขึ้นสำหรับรังสีแพทย์ อันจะเป็นการยกระดับประสิทธิภาพการตรวจจับภาวะปอดอักเสบจากภาพเอกซเรย์ทรวงอกอย่างสมบูรณ์

บทที่ 3

สรุปผลการศึกษา

3.1 สรุปผล

จากงานวิจัยที่เกี่ยวข้องกับการลดสัญญาณรบกวนในภาพเอกซเรย์ทรวงอกและการตรวจจับความผิดปกติของปอดด้วยปัญญาประดิษฐ์ จำนวน 10 ฉบับ ซึ่งครอบคลุมงานวิจัยตั้งแต่ปี ค.ศ. 2021 ถึง 2026 สามารถสรุปประเด็นสำคัญได้ดังนี้

ประการแรก งานวิจัยส่วนใหญ่มีความเห็นตรงกัน (Consensus) ว่าสัญญาณรบกวน (Noise) และสิ่งแปลกปลอมในภาพเอกซเรย์ทรวงอกส่งผลกระทบต่อความแม่นยำของแบบจำลองปัญญาประดิษฐ์ ทำให้เกิดผลบวกและผลลบลง ขั้นตอนการลดสัญญาณรบกวนก่อนการวิเคราะห์ (Preprocessing) จึงเป็นขั้นตอนที่ขาดไม่ได้ ดังที่ Rahman และคณะ (2021) แสดงให้เห็นว่าการใช้ Gamma Correction ร่วมกับ CLAHE และ U-Net Segmentation ช่วยเพิ่มความแม่นยำของโมเดล ChexNet ได้ถึง 95.11%

ประการที่สอง เทคนิคการผสมผสานหลายวิธีเข้าด้วยกัน (Fusion หรือ Ensemble Approach) ให้ผลลัพธ์ดีกว่าการใช้เทคนิคใดเทคนิคหนึ่งเพียงอย่างเดียวอย่างชัดเจน ดังที่ Thamilarasi และคณะ (2025) ซึ่งผสมผสาน Denoising Autoencoder กับ CLAHE และ Chutia และคณะ (2023) ซึ่งผสมผสาน CLAHE กับ Discrete Wavelet Transform สามารถให้ความแม่นยำสูงถึง 97-99% ซึ่งดีกว่าการใช้เทคนิคเดียวที่ให้ผลราว 93-95%

ประการที่สาม ปัญญาประดิษฐ์ที่สามารถอธิบายผลได้ (Explainable AI หรือ XAI) เช่น Grad-CAM, SHAP และ Score-CAM ได้รับการยอมรับร่วมกันว่าเป็นกุญแจสำคัญในการสร้างความน่าเชื่อถือทางคลินิก (Clinical Trust) ดังที่ Sheu และคณะ (2023) นำ SHAP และ Grad-CAM มาใช้ระบุตำแหน่งรอยโรคจนได้ความแม่นยำถึง 93.29% อย่างไรก็ตาม ความน่าเชื่อถือของ XAI ยังมีข้อจำกัดแตกต่างกันไปตามลักษณะของรอยโรค โดย Chrysoula (2023) พบว่า Grad-CAM ให้ผลดีกับรอยโรคที่มีขอบเขตชัดเจนอย่าง Cardiomegaly แต่ยังไม่น่าเชื่อถือสำหรับรอยโรคที่มีลักษณะกระจายตัวไม่ชัดเจนอย่าง Pleural Thickening

ประการที่สี่ งานวิจัยแต่ละฉบับยังมีความเห็นที่แตกต่างกัน (Disagreements) ในประเด็นการเลือกเทคนิคลดสัญญาณรบกวน โดย Chattopadhyay (2022) ยังคงยืนยันประสิทธิภาพของตัวกรองแบบดั้งเดิม (Median Filter) สำหรับสัญญาณรบกวนแบบ Poisson ในขณะที่ Song และคณะ (2025) และ Thamilarasi และคณะ (2025) สนับสนุนการใช้เทคนิคที่อาศัยการเรียนรู้เชิงลึกเป็นหลัก ซึ่งสะท้อนว่าการเลือกเทคนิคที่เหมาะสมยังขึ้นอยู่กับลักษณะของสัญญาณรบกวนและบริบทของข้อมูลเป็นสำคัญ

จากการวิเคราะห์ความเกี่ยวข้องกับภาวะปอดอักเสบ (Infiltration) โดยเฉพาะ พบว่ามีเพียงงานวิจัยของ Sheu และคณะ (2023) เท่านั้นที่ระบุเจาะจงถึงภาวะ Infiltration โดยตรง ในขณะที่งานวิจัยส่วนใหญ่มุ่งเน้นไปที่โรคที่มีขอบเขตชัดเจน เช่น ก้อนเนื้อ (Nodule) หรือภาวะปอดยุบตัว (Atelectasis) ซึ่งมีลักษณะทางภาพที่แตกต่างจากภาวะ Infiltration ที่มีลักษณะเป็นฝ้ากระจายขอบเขตไม่ชัดเจน (Diffuse/Hazy Opacity) อย่างสิ้นเชิง คณะผู้จัดทำจึงได้สังเคราะห์และระบุช่องว่างทางความรู้ (Research Gap) เมื่อโฟกัสที่ภาวะ Infiltration ออกเป็น 6 ประเด็นสำคัญ ได้แก่

1. การขาดการศึกษาเทคนิคลดสัญญาณรบกวนที่ช่วยเพิ่มความแม่นยำของภาวะฝ้ากระจายที่มีลักษณะขอบเขตไม่ชัดเจนโดยเฉพาะ
2. การขาดการทดลองเทคนิคผสมผสาน (Fusion Denoising) กับภาวะ Infiltration โดยตรง เนื่องจากงานวิจัยที่ให้ผลดีมักทดสอบกับ Nodule หรือ Atelectasis เท่านั้น
3. การขาดองค์ความรู้ว่าการลดสัญญาณรบกวนที่รุนแรงเกินไปอาจทำให้รายละเอียดของฝ้าบางจางของ Infiltration หายไปหรือไม่ (Over-smoothing)
4. ความน่าเชื่อถือของ XAI ที่ยังไม่ชัดเจนสำหรับรอยโรคแบบกระจายตัว
5. ปัญหาป้ายกำกับข้อมูลที่มีความคลาดเคลื่อนสูง (Label Noise) ซึ่งรุนแรงเป็นพิเศษสำหรับภาวะ Infiltration เนื่องจากการประเมินแบบ Subjective สูง
6. การขาดการเปรียบเทียบอย่างเป็นธรรมระหว่างตัวกรองแบบดั้งเดิมกับเทคนิคการลดสัญญาณรบกวนด้วยการเรียนรู้เชิงลึกบนชุดข้อมูลและงานเฉพาะทางเดียวกัน

โดยสรุป ผลการทบทวนวรรณกรรมชี้ให้เห็นว่า แม้เทคนิคการลดสัญญาณรบกวนร่วมกับปัญญาประดิษฐ์ที่อธิบายได้จะได้รับการพิสูจน์แล้วว่าสามารถเพิ่มประสิทธิภาพการตรวจจับความผิดปกติของปอดได้อย่างมีนัยสำคัญ แต่ยังไม่มียานวิจัยฉบับใดที่ศึกษาแนวทางดังกล่าวโดยมุ่งเน้นที่ภาวะปอดอักเสบ (Infiltration) อย่างเป็นระบบและครบถ้วน จึงเป็นที่มาของโอกาสในการพัฒนางานวิจัยต่อยอดในหัวข้อนี้

3.2 แนวทางการนำไปใช้

จากช่องว่างทางความรู้ที่ได้จากการสังเคราะห์ในบทที่ 2 ได้กำหนดแนวทางการนำไปประยุกต์ใช้ในการดำเนินโครงการต่อไป ดังนี้

1. การพัฒนาเทคนิคลดสัญญาณรบกวนแบบผสมผสาน (Fusion Denoising Technique) โดยอ้างอิงแนวทางที่ได้ผลดีจาก Thamilarasu และคณะ (2025) และ Chutia และคณะ (2023) มาปรับใช้และออกแบบให้เหมาะสมกับลักษณะฝ้าบางจางของภาวะ Infiltration โดยเฉพาะ พร้อมทั้งควบคุมระดับการลดสัญญาณรบกวนเพื่อป้องกันปัญหา Over-smoothing ที่อาจทำให้รายละเอียดของรอยโรคหายไป
2. การเปรียบเทียบประสิทธิภาพอย่าง Fair Comparison ระหว่าง Filter (เช่น Median Filter ตามแนวทางของ Chattopadhyay, 2022) กับเทคนิคการลดสัญญาณรบกวนด้วยการเรียนรู้เชิงลึก บนชุดข้อมูลและงานจำแนกภาวะ Infiltration ชุดเดียวกัน เพื่อให้ได้ข้อสรุปที่ชัดเจนว่าเทคนิคใดเหมาะสมที่สุดสำหรับภาวะนี้
3. การประยุกต์ใช้แบบจำลองปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI) โดยนำเทคนิค Grad-CAM และ SHAP ตามแนวทางของ Sheu และคณะ (2023) มาประเมินร่วมกับภาพที่ผ่านและไม่ผ่านการลดสัญญาณรบกวน เพื่อวิเคราะห์ว่าการลดสัญญาณรบกวนช่วยเพิ่มความแม่นยำในการระบุตำแหน่งของ Heatmap สำหรับรอยโรคแบบกระจายตัวได้จริงหรือไม่
4. การจัดการปัญหาคุณภาพของป้ายกำกับข้อมูล (Label Noise) โดยพิจารณาคัดเลือกและตรวจสอบชุดข้อมูลภาพเอกซเรย์ที่ตรงจากแหล่งสาธารณะที่มีความน่าเชื่อถือ ควบคู่กับการอ้างอิงเกณฑ์การวินิจฉัยที่ชัดเจนสำหรับภาวะ Infiltration เพื่อลดความคลาดเคลื่อนของป้ายกำกับข้อมูลที่อาจส่งผลต่อการฝึกโมเดล

5. การกำหนดตัวชี้วัดในการประเมินผล โดยใช้ค่า Accuracy, Precision, Recall และ F1-score ในการประเมินประสิทธิภาพของแบบจำลองจำแนกภาวะ Infiltration ร่วมกับการประเมินเชิงคุณภาพของผลลัพธ์จาก XAI เพื่อยืนยันว่าแบบจำลองตัดสินใจจากบริเวณรอยโรคจริงในภาพ

เอกสารอ้างอิง

Byeon, H., Seno, M. E., Nimma, D., Ramesh, J. V. N., Zaidi, A., AlGhamdi, A., ... & Shabaz, M. (2025). *Privacy-preserving explainable AI enable federated learning-based denoising fingerprint recognition model*. *Image and Vision Computing*, 154, 105420. <https://doi.org/10.1016/j.imavis.2025.105420>

Chattopadhyay, S. (2022). *A study on various common denoising methods on chest X-ray images*. *Artificial Intelligence Evolution*, 3(2), 87-106. <https://doi.org/10.37256/aie.3220221714>

Chrysoula, T. (2023). *Explainable artificial intelligence for deep learning methods in chest X-ray classification [Master's thesis, National and Kapodistrian University of Athens]*. <https://pergamos.lib.uoa.gr/uoa/dl/object/3396182>

Chutia, U., Tewari, A. S., & Singh, J. P. (2024). *Collapsed lung disease classification by coupling denoising algorithms and deep learning techniques*. *Network Modeling Analysis in Health Informatics and Bioinformatics*, 13(1), 1. <https://doi.org/10.1007/s13721-023-00435-0>

Dhar, T., Dey, N., Borra, S., & Sherratt, R. S. (2023). *Challenges of deep learning in medical image analysis—improving explainability and trust*. *IEEE Transactions on Technology and Society*, 4(1), 68-75. <https://doi.org/10.1109/TTS.2023.3234203>

Parra-Cabrera, G., Jimenez-Delgado, J. J., & Perez-Cano, F. D. (2026). *Artificial intelligence for pulmonary abnormality detection in chest X-ray imaging: A detailed review of methods, datasets and future directions*. *Technologies*, 14(3), 147. <https://doi.org/10.3390/technologies14030147>

Rahman, T., Khandakar, A., Qiblawey, Y., Tahir, A., Kiranyaz, S., Kashem, S. B. A., ... & Chowdhury, M. E. (2021). *Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images*. *Computers in biology and medicine*, 132, 104319. <https://doi.org/10.1016/j.compbimed.2021.104319>

Sheu, R. K., Pardeshi, M. S., Pai, K. C., Chen, L. C., Wu, C. L., & Chen, W. C. (2023). *Interpretable classification of pneumonia infection using eXplainable AI (XAI-ICP)*. *IEEE Access*, 11, 28896-28919. <https://doi.org/10.1109/ACCESS.2023.3255403>

Song, L., Sun, H., Xiao, H., Lam, S. K., Zhan, Y., Ren, G., & Cai, J. (2025). *Artificial intelligence for chest X-ray image enhancement*. *Radiation Medicine and Protection*, 6(01), 61-68. <https://doi.org/10.1016/j.radmp.2024.12.003>

Thamilarasi, V., Asaithambi, A., & Roselin, R. (2025). *Enhanced ensemble segmentation of lung chest X-ray images by denoising autoencoder and CLAHE*. *ICTACT Journal on Image and Video Processing*, 15(3), 3501-3508. <https://doi.org/10.21917/ijivp.2025.0496>

ความคิดเห็นอาจารย์ที่ปรึกษา

.....

.....

.....

.....

.....

.....

ลายเซ็น.....